### Modulo 3: Classificazione del Testo e Analisi del Sentiment 🍑 😊

Corso di Natural Language Processing

#### **Contenuti del modulo**

- Classificazione del testo: concetti fondamentali
- El Approcci tradizionali: Naive Bayes, SVM, Logistic Regression
- **Approcci neurali**: RNN, CNN, Transformer
- Caralisi del sentiment: teoria e sfide specifiche
- Applicazioni pratiche in contesti aziendali
- **K** Implementazione e considerazioni etiche



#### Classificazione del testo: concetti fondamentali

"La classificazione del testo è il processo di assegnazione di categorie predefinite a documenti testuali."

- **Input**: documento testuale (email, recensione, articolo, tweet...)
- **Output**: una o più categorie/etichette
- **Obiettivo**: generalizzare dai dati di addestramento a nuovi documenti
- 🔁 **Processo**: supervisionato (richiede esempi etichettati)



#### Tipi di problemi di classificazione

- O T Classificazione binaria: due classi (spam/non-spam)
- Classificazione multi-classe: più classi mutuamente esclusive (categorie di notizie)
- Classificazione multi-label: più etichette contemporaneamente (tag di un articolo)
- III Classificazione gerarchica: categorie organizzate in struttura ad albero

#### Pipeline di classificazione del testo

- 1. **Raccolta dati** etichettati
- 2. **Preprocessing** del testo
- 3. Feature extraction
- 4. **Addestramento** del modello
- 5. **III Valutazione** delle performance
- 6. **Deployment** in produzione

#### Preprocessing e Feature Extraction

#### **Preprocessing:**

- Tokenizzazione (divisione in parole/token)
- Normalizzazione (minuscolo, rimozione punteggiatura)
- Namozione stopwords ("il", "la", "e", "di"...)
- Stemming/Lemmatizzazione (riduzione alla forma base)
   Feature Extraction:
- **Bag-of-Words (BoW)**: conteggio delle parole
- III TF-IDF: frequenza del termine × inverso della frequenza nei documenti
- N-grams: sequenze di N parole consecutive
- Word Embeddings: Word2Vec, GloVe, FastText
- Embeddings contestuali: BERT, RoBERTa

#### Approcci tradizionali: Naive Bayes

- III Basato sul teorema di Bayes con assunzione di indipendenza
- $\blacksquare$   $P(y|x) \propto P(y) \prod_{i=1}^n P(x_i|y)$
- 🚀 Veloce, efficiente, poco costoso computazionalmente
- 👍 Funziona sorprendentemente bene per classificazione testuale

#### Varianti:

- **Multinomial NB**: conta le occorrenze (per BoW)
- 0 1 Bernoulli NB: presenza/assenza di feature (per testi brevi)
- **K** Gaussian NB: per feature continue

# Approcci tradizionali: Support Vector Machine (SVM)

- Trova l'iperpiano ottimale che separa le classi
- Q Massimizza il margine tra le classi
- Molto efficace per testi, specialmente con feature TF-IDF
- A Può essere lento su dataset molto grandi

#### Approcci tradizionali: Logistic Regression

- Modello lineare per classificazione probabilistica
- $\blacksquare P(y=1|x) = \frac{1}{1+e^{-w^Tx}}$
- Semplice, interpretabile, efficace
- Fornisce probabilità (non solo etichette)
- K Facilmente estendibile a classificazione multi-classe

### Approcci tradizionali: Random Forest e Gradient Boosting

- A Random Forest: ensemble di alberi decisionali
  - Addestra molti alberi su sottoinsiemi casuali di dati e feature
  - Combina le previsioni tramite voto di maggioranza
  - Robusto all'overfitting, gestisce bene feature irrilevanti
- **K** Gradient Boosting: costruisce modelli sequenzialmente
  - Ogni nuovo modello corregge gli errori dei precedenti
  - Spesso ottiene performance state-of-the-art (XGBoost, LightGBM)
  - Richiede tuning attento degli iperparametri

#### Approcci neurali: Reti Neurali Feed-Forward

- Input: rappresentazioni vettoriali del testo (BoW, TF-IDF, embeddings)
- Hidden layers con attivazioni non lineari
- Output layer con softmax per probabilità di classe
- le Può catturare pattern complessi
- Richiede più dati rispetto ai modelli classici
- Non cattura naturalmente la sequenzialità del testo

#### Approcci neurali: Reti Neurali Ricorrenti (RNN)

- Processano sequenze elemento per elemento, mantenendo uno stato nascosto
- Warianti avanzate: LSTM (Long Short-Term Memory) e GRU (Gated Recurrent Unit)
- le Catturano dipendenze sequenziali e contestuali
- Gestiscono input di lunghezza variabile
- Addestramento più complesso, problemi di gradienti svanescenti
- Processamento sequenziale lento (non parallelizzabile)

#### Approcci neurali: Reti Neurali Convoluzionali (CNN)

- • Applicano filtri convoluzionali per catturare pattern locali
- ♣ Architettura tipica: embedding → convoluzione → max-pooling → fully connected
- 🔸 👍 Efficaci per catturare n-grammi e pattern locali
- Più veloci da addestrare rispetto alle RNN
- O Non catturano dipendenze a lungo termine come le RNN
- Sorprendentemente efficaci per la classificazione testuale

#### Approcci neurali: Transformer

- C Processano l'intera sequenza in parallelo
- ## Pre-addestrati su enormi corpora (BERT, RoBERTa, XLNet...)
- State-of-the-art per la maggior parte dei task NLP
- L Computazionalmente costosi, richiedono GPU
- Limitazioni sulla lunghezza dell'input

#### **Analisi del sentiment**

#### Analisi del sentiment: concetti fondamentali

"L'analisi del sentiment è il processo di determinazione dell'attitudine, opinione o emozione espressa in un testo."

- **Obiettivo**: identificare e quantificare il sentiment espresso
- III Granularità: documento, frase, aspetto, entità
- Approcci: basati su lessico, machine learning, ibridi
- Qutput: categorico (pos/neg/neutro) o continuo (score)

#### C Livelli di analisi del sentiment

- **Example 2 Livello documento**: sentiment globale dell'intero documento
  - "Questo prodotto è fantastico. Altamente consigliato!"
- **<u>livello frase</u>**: sentiment di singole frasi
  - o "L'interfaccia è intuitiva, ma la batteria si scarica velocemente."
- @ Livello aspetto: sentiment verso specifici aspetti/caratteristiche
  - "La fotocamera è eccellente [+], ma il prezzo è troppo alto [-]."
- **Livello entità**: sentiment verso specifiche entità
  - "Apple ha rilasciato un ottimo prodotto, ma Samsung resta leader."

#### Approcci all'analisi del sentiment

- E Approcci basati su lessico:
  - Utilizzano dizionari di parole con polarità predefinite
  - Es: VADER, SentiWordNet, AFINN
  - le Non richiedono addestramento
  - F Limitati da espressioni complesse, sarcasmo, contesto
- Approcci basati su machine learning:
  - Supervisionati: Naive Bayes, SVM, deep learning
  - leading
     leading
  - Pichiedono dati etichettati

#### Sfide nell'analisi del sentiment

- Sarcasmo e ironia: "Fantastico, un altro aggiornamento che rallenta tutto!"
- **Negazioni**: "Il prodotto non è male" (positivo, non negativo)
- National interestriction in the street of the street in the street in
- **Espressioni idiomatiche**: "costare un occhio della testa"
- \* Ambiguità: "Il film era incredibile" (positivo o negativo?)
- Pifferenze culturali e linguistiche: variazioni nell'espressione di emozioni
- 🔸 📘 Emoji e emoticon: 😊 vs 🙄 (richiedono interpretazione specifica)

#### Valutazione dei classificatori testuali

• **Accuracy**: proporzione di previsioni corrette

$$\circ$$
 Accuracy =  $\frac{\text{Corrette}}{\text{Totale}}$ 

• **III Precision**: proporzione di positivi identificati correttamente

$$\circ \text{ Precision} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Positives}}$$

• Recall: proporzione di positivi reali identificati

$$\circ \text{ Recall} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

• **Q. F1-Score**: media armonica di precision e recall

$$\circ \ \mathrm{F1} = 2 imes rac{\mathrm{Precision} imes \mathrm{Recall}}{\mathrm{Precision} + \mathrm{Recall}}$$

### **Valutazione:**Confusion Matrix

- Tabella che mostra le previsioni vs. realtà
- Rivela pattern di errori specifici
- Particolarmente utile per classi sbilanciate
- Base per calcolare precision, recall, F1
- Essenziale per comprendere il comportamento del modello oltre le metriche aggregate

### Valutazione: ROC Curve e AUC

- **ROC**: Receiver Operating Characteristic
- Mostra il trade-off tra true positive rate e false positive rate
- III AUC: Area Under the Curve
  - 1.0 = classificatore perfetto
  - 0.5 = classificatore casuale
- le Robusta rispetto a classi sbilanciate
- Utile per confrontare modelli e scegliere soglie di decisione

#### Caso di studio: Analisi delle recensioni dei clienti

Azienda: Catena di hotel internazionale

Sfida: Analizzare migliaia di recensioni per identificare punti di forza e debolezza

#### Soluzione:

- 1. 

  Preprocessing delle recensioni
- 2. Caralisi del sentiment a livello di aspetto (pulizia, personale, posizione, prezzo...)
- 3. III Dashboard con trend temporali e confronto tra strutture
- 4. Alert automatici per problemi ricorrenti

Risultato: Miglioramento del 15% nella soddisfazione dei clienti in 6 mesi

### Caso di studio: Monitoraggio della reputazione del brand

Azienda: Produttore di elettronica di consumo

Sfida: Monitorare la percezione del brand sui social media e forum

#### Soluzione:

- 1. Raccolta continua di menzioni del brand
- 2. Section 2. Classificazione per tema (qualità, prezzo, supporto, innovazione...)
- 3. Chalisi del sentiment per tema
- 4. III Dashboard in tempo reale con alert

**Risultato**: Identificazione precoce di una potenziale crisi PR, con risposta rapida che ha limitato l'impatto negativo

## Caso di studio: Classificazione automatica di ticket di supporto

Azienda: Software as a Service (SaaS)

Sfida: Smistare automaticamente migliaia di ticket di supporto

#### Soluzione:

- 1. 

  Classificatore multi-classe basato su BERT
- 2. © Categorizzazione in 20+ categorie (bug, domande di fatturazione, richieste di feature...)
- 3. Sistema di feedback per miglioramento continuo
- 4. 👤 Integrazione con sistema di assegnazione agli specialisti

#### X Implementazione pratica: considerazioni tecniche

- Dipeline end-to-end: dalla raccolta dati al deployment
- Scalabilità: gestione di volumi crescenti di dati
- 🕭 Latenza: tempo di risposta accettabile per l'applicazione
- **Robustezza**: gestione di input anomali e casi edge
- **Monitoraggio**: tracking delle performance nel tempo
- E Feedback loop: meccanismi per miglioramento continuo
- S Costi: bilanciamento tra performance e risorse computazionali

#### **X** Considerazioni etiche e bias

- Pias nei dati di addestramento: riflettono pregiudizi umani
- **Trasparenza algoritmica**: comprensione delle decisioni
- **Privacy**: gestione di dati sensibili o personali
- ## Fairness: equità tra gruppi demografici
- C Accountability: responsabilità per le decisioni automatizzate
- III Audit regolari: verifica continua di bias e performance
- **Human-in-the-loop**: supervisione umana per decisioni critiche

#### **X** Tecniche di interpretabilità

- **Q. Feature importance**: quali parole influenzano maggiormente la decisione
- III LIME (Local Interpretable Model-agnostic Explanations): spiega singole predizioni
- **SHAP** (SHapley Additive exPlanations): contributo di ogni feature
- Attention visualization: visualizzazione dei pesi di attenzione
- Counterfactual explanations: "cosa cambierebbe la predizione?"
- Spiegazioni in linguaggio naturale: traduzione delle decisioni in testo comprensibile

#### X Strumenti e librerie per classificazione testuale

- Escikit-learn: implementazioni di algoritmi classici
- **TensorFlow/Keras e PyTorch**: framework per deep learning
- Representation of the second of the second
- CONLTK e TextBlob: strumenti per analisi del sentiment basata su lessico
- **Q** spaCy: pipeline NLP end-to-end
- III LIME e SHAP: strumenti per interpretabilità dei modelli
- MLflow: tracking di esperimenti e gestione di modelli



#### Concetti chiave da ricordare

- La classificazione testuale è un task supervisionato fondamentale nell'NLP
- 🔳 Algoritmi classici (NB, SVM) sono ancora rilevanti per molti casi d'uso
- Deep learning offre performance superiori ma richiede più dati e risorse
- C'analisi del sentiment può essere applicata a diversi livelli di granularità
- III La valutazione deve considerare metriche appropriate al contesto
- E Le applicazioni aziendali spaziano dal customer service al brand monitoring
- X Implementazione e considerazioni etiche sono cruciali per il successo

#### **Risorse per approfondire**

- Paper: "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding" (Devlin et al., 2019)
- Pataset: IMDB Reviews, Amazon Reviews, Twitter Sentiment
- **Tutorial**: "Text Classification with BERT" (TensorFlow)
- Elbrerie: VADER per sentiment analysis, Hugging Face per classificazione
- **III Competizioni**: Kaggle text classification challenges
- **E Libro**: "Natural Language Processing with Transformers" (Lewis et al., 2021)

#### **Domande?**

Prossimo modulo: Modelli Linguistici e Sequence-to-Sequence

### Grazie per l'attenzione!