# Modelli Linguistici e Sequence-to-Sequence 🧠

## Comprendere, Predire e Generare Linguaggio Naturale

# Indice dei contenuti 📋

# Introduzione ai modelli linguistici 🔍

I modelli linguistici (Language Models o LM):

- Sistemi **probabilistici** che assegnano probabilità a sequenze di parole
- Predicono quale parola è più probabile che segua una determinata sequenza
- Alla base di numerose applicazioni NLP quotidiane:
  - 📱 Correzione automatica sui nostri smartphone
  - 🤖 Assistenti virtuali come Siri, Alexa, Google Assistant
  - 🌐 Traduzione automatica
  - ✍️ Generazione di testo

# L'evoluzione dei modelli linguistici ⏳

| Periodo | Approccio | Caratteristiche |
|---|---|---|
| Anni '80-'00 | **Modelli statistici (N-gram)** | Basati su conteggi, context locale |
| Anni '10 | **Reti neurali ricorrenti (RNN)** | Rappresentazioni dense, memoria limitata |
| Anni '10-'15 | **LSTM e GRU** | Migliore gestione dipendenze a lungo termine |
| 2017-oggi | **Transformer** | Basati su attenzione, altamente parallelizzabili |
| 2018-oggi | **Modelli pre-addestrati** | Transfer learning, miliardi di parametri |

# 🤔 Quanto è importante predire la parola successiva?

Completa la frase: "Il cielo oggi è particolarmente _____"

# Cos'è un modello linguistico 📊

> Un modello probabilistico che assegna una probabilità a una sequenza di parole

- **Framework left-to-right**:
  $P(w_1, w_2, ..., w_n) = P(w_1) \times P(w_2|w_1) \times P(w_3|w_1,w_2) \times ... \times P(w_n|w_1,...,w_{n-1})$
- **Applicazioni fondamentali**:
  - Completamento predittivo ✅
  - Correzione ortografica e grammaticale 📝
  - Generazione di testo 📃
  - Valutazione della fluidità del linguaggio 🔄
  - Disambiguazione 🔍

# Valutazione dei modelli linguistici: Perplexity 📏

La perplexity misura quanto il modello è "sorpreso" da un testo di test:

$$Perplexity = 2^{-\frac{1}{N}\sum_{i=1}^{N}\log_2 P(w_i|w_1,...,w_{i-1})}$$

- **Interpretazione**: Se un modello ha perplexity 100, è come se stesse scegliendo uniformemente tra 100 possibili parole ad ogni passo
- **Obiettivo**: Perplexity più bassa = modello migliore

# Caso Aziendale: Settore Editoriale 🗞️

**Applicazioni:**

- Assistenza alla scrittura con suggerimenti contestuali
- Controllo automatico di leggibilità e tono
- Generazione di titoli ottimizzati
- Adattamento stilistico per diversi pubblici

**Esempio reale:**

The Associated Press utilizza modelli linguistici per automatizzare la produzione di report finanziari e sportivi di base, generando migliaia di articoli trimestrali sui risultati aziendali e resoconti di partite.

# Modelli N-gram 🧩

Il mattone fondamentale dei modelli linguistici statistici

# Principio di funzionamento degli N-gram 🔄

Approccio probabilistico basato sull'**assunzione markoviana**: il futuro dipende dal passato solo attraverso il presente

- **Unigram (n=1)**: $P(w_i)$ - Solo frequenza individuale delle parole
- **Bigram (n=2)**: $P(w_i|w_{i-1})$ - Solo la parola precedente
- **Trigram (n=3)**: $P(w_i|w_{i-2},w_{i-1})$ - Due parole precedenti

**Stima delle probabilità**: conteggio delle frequenze relative

$$P(w_i|w_{i-n+1},\ldots,w_{i-1}) \approx \frac{count(w_{i-n+1},\ldots,w_i)}{count(w_{i-n+1},\ldots,w_{i-1})}$$

# Il problema della sparsità 📊

Anche con corpora enormi, molte sequenze valide non appariranno mai!

**Tecniche di smoothing**:

- **Add-one (Laplace)**: Aggiunge 1 a tutti i conteggi
- **Good-Turing**: Riserva probabilità per eventi mai visti
- **Kneser-Ney**: Considera la diversità dei contesti
- **Interpolazione**: Combina modelli di diversi ordini
- **Backoff**: "Retrocede" a modelli di ordine inferiore quando necessario

# Vantaggi e limitazioni dei modelli N-gram ⚖️

### 👍 Vantaggi:

- Semplicità concettuale
- Efficienza computazionale
- Interpretabilità diretta
- Buone performance in domini specifici

### 👎 Limitazioni:

- Incapacità di catturare dipendenze a lungo termine
- Crescita esponenziale dei parametri con n
- Difficoltà con parole rare
- Nessuna nozione di similarità semantica

# Modelli linguistici neurali 🧠

Superano i modelli N-gram grazie a:

1. **Rappresentazioni dense** (word embeddings)
    - Parole simili hanno vettori simili
    - Dimensionalità ridotta
2. **Reti neurali potenti**
    - Apprendimento automatico di feature
    - Capacità di modellare relazioni complesse
3. **Generalizzazione migliore**
    - Performance superiori su sequenze mai viste
    - Comprensione di relazioni semantiche

# Modelli basati su reti neurali ricorrenti (RNN) 🔄

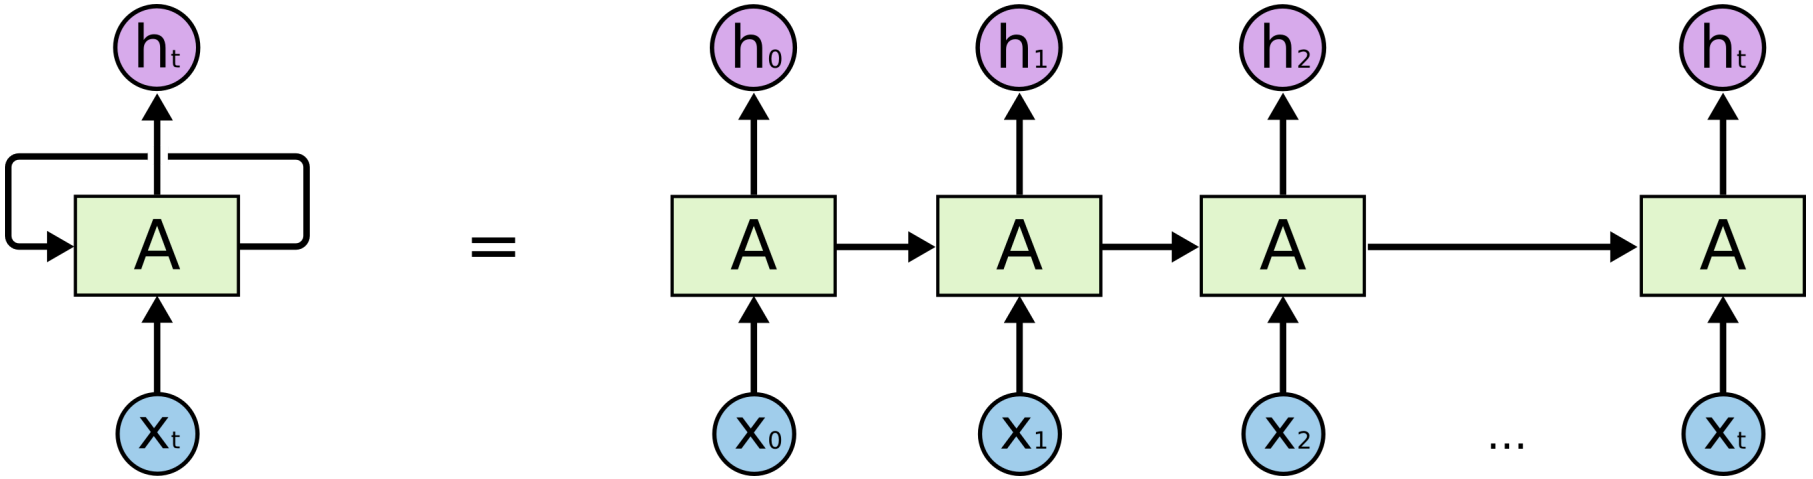


Le RNN processano le sequenze elemento per elemento, mantenendo uno **stato nascosto** che viene aggiornato ad ogni passo.

$$h_t = \tanh(W_{hx} \cdot x_t + W_{hh} \cdot h_{t-1} + b_h)$$

$$y_t = \text{softmax}(W_y \cdot h_t + b_y)$$

# Il problema del vanishing gradient e le soluzioni 📉

Le RNN standard hanno difficoltà a catturare dipendenze a lungo termine a causa del **vanishing gradient**.

**Soluzioni: LSTM e GRU**

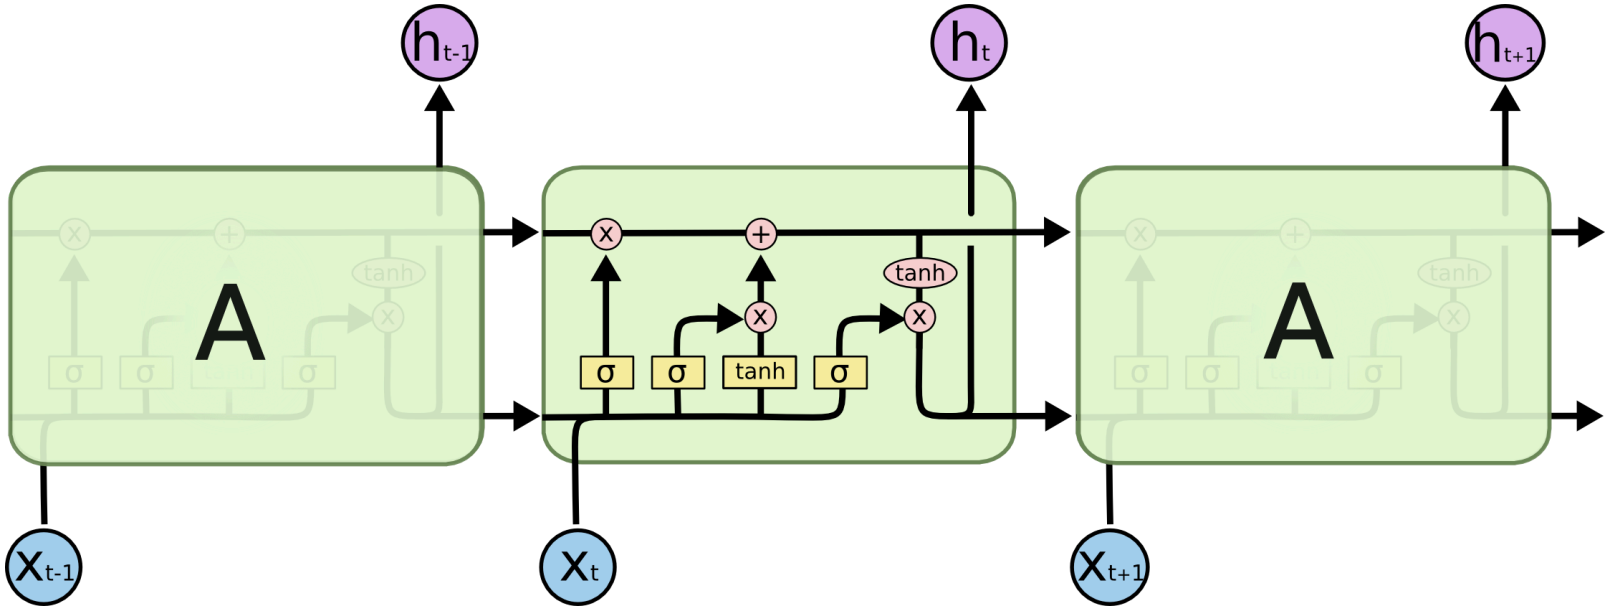


- **Long Short-Term Memory (LSTM)**: Celle di memoria con gate di input, forget e output
- **Gated Recurrent Unit (GRU)**: Versione semplificata con gate di reset e update

# Modelli bidirezionali e CNN per il testo ↔️

### Modelli bidirezionali

- Due RNN separate:
  - Una da sinistra a destra
  - Una da destra a sinistra
- Combinano informazioni da entrambe le direzioni

### Reti neurali convoluzionali (CNN)

- Applicano filtri su finestre di parole
- Catturano pattern locali (simili a n-gram)
- Vantaggi:
  - Parallelizzabilità
  - Efficienza computazionale

# Weight tying e altre ottimizzazioni 🔧

**Weight tying**: Condivide i pesi tra lo strato di embedding e lo strato di output

- Riduce significativamente il numero di parametri
- Migliora la generalizzazione

**Altre ottimizzazioni**:

- **Adaptive softmax**: Gerarchia di classificatori per vocabolari grandi
- **Sampled softmax**: Approssimazione durante l'addestramento
- **Mixture of Softmaxes (MoS)**: Combinazione di multiple distribuzioni

# Caso Aziendale: Settore Finanziario 💹

**Applicazioni:**

- Analisi automatica di report finanziari
- Identificazione di segnali predittivi di mercato
- Monitoraggio del sentiment in tempo reale
- Generazione di sintesi e report automatizzati

**Esempio reale:**

Bloomberg utilizza modelli linguistici avanzati per analizzare migliaia di notizie finanziarie al minuto, identificando eventi rilevanti per il mercato e fornendo insights in tempo reale ai trader.

# Il framework Sequence-to-Sequence 🔄

Trasformare una sequenza in un'altra sequenza

# Architettura Encoder-Decoder 🏗️

### Encoder

- Processa la sequenza di input
- Tipicamente una RNN bidirezionale
- Produce una rappresentazione che cattura le informazioni rilevanti

### Decoder

- Modello linguistico condizionato sulla rappresentazione dell'encoder
- Opera in modo auto-regressivo:
    i. Inizia con token <start>
    ii. Predice parola per parola
    iii. Termina con token <end>

# Sfide dell'architettura Seq2Seq base 🧩

- **Collo di bottiglia dell'informazione**: Comprimere tutto in un singolo vettore
- **Perdita di informazioni**: Dettagli dall'inizio tendono a "svanire"
- **Disallineamento**: Difficoltà con relazioni non monotone tra input e output
- **Esposizione al bias**: Discrepanza tra addestramento (input corretti) e inferenza (input predetti)

**Tecniche di inferenza**:

- **Greedy decoding**: Seleziona sempre la parola più probabile
- **Beam search**: Mantiene le k sequenze più probabili
- **Sampling**: Campiona dalla distribuzione (top-k, nucleus/top-p, temperature)

# Valutazione dei modelli Seq2Seq 📊

La valutazione varia a seconda del compito specifico:

- **Traduzione automatica**:
  - BLEU, METEOR, TER - confrontano con riferimenti umani
- **Riassunto automatico**:
  - ROUGE - misura sovrapposizione di n-gram con riferimenti
- **Generazione di dialogo**:
  - Perplexity, diversità lessicale, valutazione umana
- **Valutazione umana**:
  - Fondamentale per aspetti qualitativi (naturalezza, coerenza, utilità)

## 🤔 Come comunichereste un messaggio complesso?

Immaginate di dover tradurre una frase lunga e complessa in una lingua straniera, parola per parola...

Sarebbe meglio:

A) Memorizzare l'intera frase e poi tradurla

B) Guardare a parti specifiche della frase mentre traducete

# Il meccanismo di attenzione 👁️

**Motivazione**: Permettere al decoder di "focalizzarsi" selettivamente su parti dell'input durante la generazione di ciascuna parola

**Vantaggi**:

- Elimina il collo di bottiglia dell'informazione
- Permette di gestire sequenze lunghe
- Facilita l'apprendimento di allineamenti complessi
- Fornisce interpretabilità

# Tipi di attenzione 🧩

### Per copertura

- **Globale**: Considera tutte le parole
- **Locale**: Solo una finestra di parole

### Per meccanismo

- **Soft**: Pesi continui, differenziabile
- **Hard**: Selezione discreta

### Per interazione

- **Self-Attention**: Sequenza interagisce con se stessa
- **Cross-Attention**: Interazione tra sequenze diverse

### Per complessità

- **Single-Head**: Un unico meccanismo
- **Multi-Head**: Attenzione in parallelo con diverse proiezioni

# L'architettura Transformer 🤖

"Attention is All You Need" (Vaswani et al., 2017)

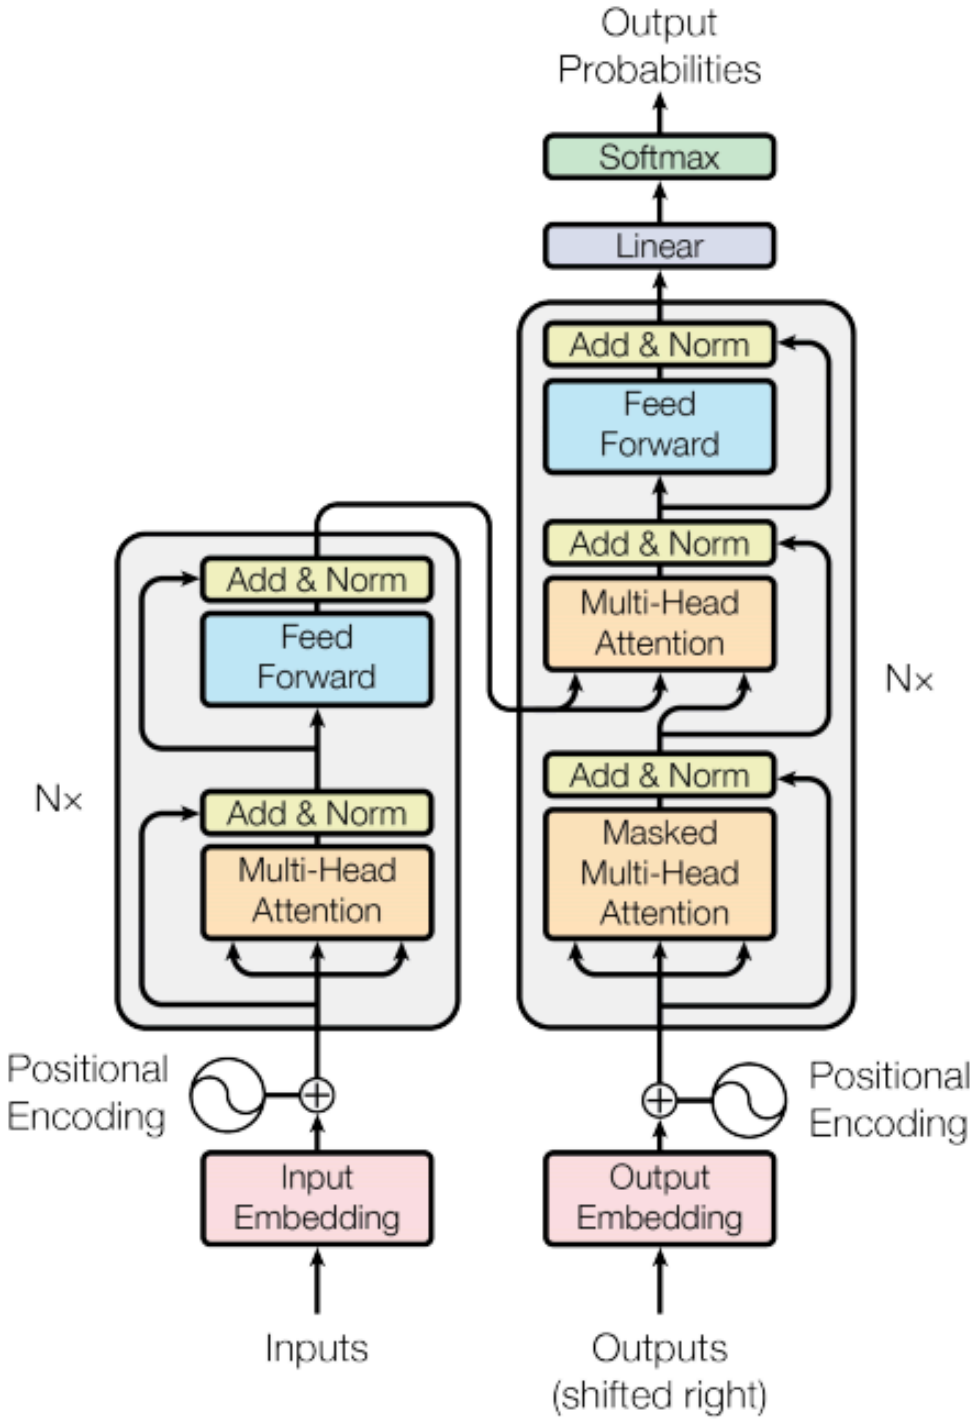

# Principi fondamentali del Transformer 🧩

**Innovazioni chiave:**

- **Parallelizzazione completa**: Elabora l'intera sequenza contemporaneamente
- **Self-attention**: Ogni posizione interagisce con tutte le altre
- **Rappresentazioni posizionali**: Informazioni esplicite sulla posizione
- **Architettura encoder-decoder**: Mantiene la struttura generale Seq2Seq

**Vantaggi rispetto a RNN/CNN:**

- Cattura efficacemente dipendenze a lungo termine
- Addestramento molto più veloce
- Path length costante tra qualsiasi coppia di posizioni
- Maggiore scalabilità

# 🤖 Immaginate di essere un Transformer!

Come processereste questa frase?

"Il gatto che spavenò il topo, che il formaggio attirò, è nero"

**Pensate all'attenzione tra parole** - Questa frase è un esempio di costruzione sintattica annidativa complessa

# Subword Segmentation 🧬

La segmentazione a livello di subword affronta il problema del **vocabolario aperto**:

- **Il problema delle parole fuori vocabolario (OOV)**:
  - Vocabolari enormi per lingue morfologicamente ricche
  - Inefficienza nella gestione di forme flesse
  - Neologismi e nomi propri non gestibili
- **Principio della segmentazione subword**:
  - Dividere le parole in unità più piccole e frequenti
  - Catturare componenti morfologici significativi
  - Permettere di rappresentare qualsiasi parola come sequenza di subword

# Algoritmi principali di segmentazione 🔍

### Byte Pair Encoding (BPE)

- Inizia con caratteri singoli
- Unisce iterativamente le coppie più frequenti
- Usato in GPT, RoBERTa

### WordPiece

- Simile a BPE ma diverso criterio di selezione
- Massimizza la verosimiglianza del corpus
- Usato in BERT

### SentencePiece

- Tratta il testo come sequenza di Unicode bytes
- Gestisce qualsiasi lingua senza pre-tokenizzazione
- Ideale per modelli multilingue

**Esempio di segmentazione**: "inimmaginabile" → "in + immagin + abile"

# Impatto sui modelli linguistici e Seq2Seq 📈

La segmentazione subword ha trasformato i modelli NLP moderni:

- **Vocabolari più compatti**: 30-50K token invece di centinaia di migliaia
- **Eliminazione del problema OOV**: Qualsiasi parola può essere rappresentata
- **Migliore generalizzazione morfologica**: Riconoscimento di pattern anche in parole rare
- **Efficacia multilingue**: Condivisione di subword tra lingue con radici comuni
- **Gestione di neologismi e nomi propri**: Scomposizione in componenti familiari

https://tiktokenizer.vercel.app/

# Architettura dei Transformers

## Panoramica delle Varianti e dei loro Utilizzi

| Architettura | A cosa serve meglio (tipi di task) | Esempi di modelli celebri | Punti di forza | Limiti tipici |
|---|---|---|---|---|
| Encoder-only | - Classificazione di testo (sentiment, topic, ecc.)<br>- Named-Entity Recognition (NER)<br>- Feature extraction / embedding per retrieval o clustering<br>- Similarità semantica / semantic search | BERT, RoBERTa, ALBERT, DistilBERT, ELECTRA | • Cattura finemente le relazioni nel contesto bidirezionale<br>• Ottimo per “capire” un testo e produrre un vettore o un’etichetta | • Non genera testo autonomamente<br>• Sequence length spesso limitata |
| | - Language modeling autoregressivo<br>- Generazione di | | • Eccellente fluidità | • Non “vede” il futuro della |

| Architettura | A cosa serve meglio (tipi di task) | Esempi di modelli celebri | Punti di forza | Limiti tipici |
|---|---|---|---|---|
| Encoder-Decoder (seq2seq) | - Traduzione automatica<br>- Riassunti (summarization)<br>- Parafrasi, riscrittura controllata<br>- Question Answering estrattivo/generativo<br>- Data-to-text, code-to-comment, ecc. | T5, BART, mBART, Pegasus, FLAN-T5 | • Encoder capisce l'input completo; decoder genera un output nuovo → flessibilità nei compiti input→output<br>• Molto forte su task supervisionati con coppie (input, output) | • Modelli più pesanti (doppia rete)<br>• Add-to-cost per training/inference rispetto a soli encoder o soli decoder |

## Come Scegliere l'Architettura Giusta

- Serve “capire” un testo e restituire un’etichetta o un embedding?
  → Encoder-only
- Serve “scrivere” contenuti lunghi partendo da un prompt breve?
  → Decoder-only
- Serve trasformare A in B (due sequenze diverse), ad es. tradurre, sintetizzare o spiegare codice?
  → Encoder-Decoder

# Traduzione automatica neurale 🌐

**Evoluzione:**

- Sistemi basati su regole
- Sistemi statistici (SMT)
- Sistemi neurali (NMT) con RNN
- Transformer-based NMT

**Sfide specifiche:**

- Lingue a basse risorse
- Fenomeni linguistici complessi
- Valutazione della qualità
- Adattamento al dominio

# Riassunto automatico e generazione di testo 📝

**Riassunto automatico:**

- **Estrattivo**: Seleziona frasi esistenti
- **Astrattivo**: Genera nuove frasi
- **Applicazioni**: Notizie, documenti legali, letteratura scientifica, meeting

**Generazione di testo creativo:**

- **Tipi**: Narrativa, poesia, sceneggiature, marketing
- **Sfide**: Coerenza a lungo termine, originalità, controllo stilistico
- **Uso**: Assistenza creativa, generazione di contenuti, scrittura collaborativa

**Impatto nel settore assicurativo**: Condensazione di report di sinistri e documentazione medica, permettendo ai periti di valutare rapidamente i casi e accelerando il processo di gestione.

# Sistemi di dialogo e assistenti virtuali 🤖

**Componenti:**

- **NLU**: Comprensione del linguaggio
- **Gestione del dialogo**: Contesto e decisioni
- **NLG**: Generazione di risposte

**Tipi:**

- **Task-oriented**: Focalizzati su compiti specifici
- **Open-domain**: Conversazione generale
- **Ibridi**: Combinano entrambi gli approcci

**Impatto nel settore bancario**: Assistenti virtuali gestiscono richieste comuni come controllo del saldo, trasferimenti e informazioni su prodotti, riducendo il carico sui call center e migliorando la soddisfazione del cliente.

# Analisi e generazione di codice 💻

Un'applicazione emergente con enorme potenziale:

- **Completamento di codice**: Suggerimento di linee o blocchi successivi
- **Traduzione tra linguaggi**: Conversione da un linguaggio all'altro
- **Documentazione automatica**: Generazione di commenti chiari
- **Debugging assistito**: Identificazione e correzione di errori
- **Generazione da descrizioni**: Creazione di codice da specifiche testuali

**Impatto nello sviluppo software**: Strumenti come GitHub Copilot aumentano la produttività fino al 30%, particolarmente per compiti come scrittura di test, funzioni boilerplate e conversione tra formati di dati.

# 🤯 Come hanno cambiato la tua vita?

**Quali di queste applicazioni utilizzi regolarmente?**

**Come hanno cambiato il tuo modo di lavorare o comunicare?**

**Quali limitazioni o problemi hai riscontrato?**

# Sfide etiche e considerazioni pratiche ⚖️

L'adozione di modelli linguistici avanzati solleva importanti questioni:

### Bias e fairness

- Bias di genere, razziali, socioeconomici, culturali
- Strategie: diversificazione dei dati, debiasing, valutazione disaggregata

### Contenuti dannosi o ingannevoli

- Disinformazione, contenuti offensivi, phishing, violazioni di copyright
- Prevenzione: filtraggio, watermarking, educazione degli utenti

### Efficienza e sostenibilità

- Costi energetici, emissioni di carbonio, accessibilità
- Ottimizzazione: distillazione, quantizzazione, pruning, architetture efficienti

# Implementazione in produzione 🔧

Portare modelli linguistici avanzati in ambienti reali presenta sfide specifiche:

## Considerazioni tecniche

- **Latenza**: Tempi di risposta per applicazioni interattive
- **Scalabilità**: Gestione di volumi variabili di richieste
- **Monitoraggio**: Tracking delle performance nel tempo
- **Aggiornamento**: Strategie per l'evoluzione dei modelli

## Best practices

- **Architettura a più livelli**: Modelli di diverse dimensioni per diversi compiti
- **Caching**: Memorizzazione di risposte comuni
- **Fallback graceful**: Meccanismi di backup
- **A/B testing**: Valutazione comparativa di diverse versioni

# Conclusione 🎯

I modelli linguistici e Seq2Seq rappresentano una rivoluzione nel modo in cui le macchine comprendono e generano linguaggio:

- Da semplici modelli N-gram a sofisticate architetture Transformer
- Il meccanismo di attenzione come svolta concettuale fondamentale
- La segmentazione subword come soluzione al problema del vocabolario aperto
- Applicazioni che trasformano settori e creano nuove possibilità
- Sfide etiche e pratiche che richiedono un approccio responsabile

**Il futuro**: Modelli più efficienti, controllabili e allineati con i valori umani

# Grazie per l'attenzione! 🙏

**Domande?**